

Informe del Proyecto de Clasificación

1. Introducción

Este proyecto tiene como objetivo entrenar, evaluar y comparar tres modelos de clasificación diferentes utilizando un conjunto de datos sobre la calidad de vinos. Las técnicas utilizadas incluyen **Logistic Regression**, **K-Nearest Neighbors (KNN)** y **Random Forest**. La métrica principal para evaluar los modelos fue la exactitud (accuracy), junto con otras métricas clave como precisión, recall, F1-Score y el área bajo la curva ROC (AUC).

2. Descripción de los Datos

Los datos utilizados en este análisis corresponden a las características físico-químicas de vinos (rojos y blancos) para predecir la calidad como "**buena**" (≥ 6) o "**mala**" (< 6). Los datos incluyen:

- **Variables de entrada (X):** Características físico-químicas (pH, acidez, azúcar, etc.).
 - **Variable objetivo (y):** Clase binaria: **1** (buena calidad), **0** (mala calidad).
-

3. Preparación de los Datos

1. **Clasificación Binaria:** Se transformó la columna *quality* en una variable binaria.
 2. **División en conjuntos de datos:** Se utilizó `train_test_split` con un **80%** de datos para entrenamiento y **20%** para prueba.
 3. **Escalado:** Se aplicó **StandardScaler** para estandarizar las características numéricas.
-

4. Modelos Entrenados

4.1 Logistic Regression

- **Descripción:** Modelo lineal simple que predice la probabilidad de una clase utilizando una función logística.
- **Métricas de Evaluación:**
 - **Accuracy:** 73.5%
 - **Precision:** Clase 0: 71%, Clase 1: 76%
 - **Recall:** Clase 0: 74%, Clase 1: 73%
 - **F1-Score:** Clase 0: 73%, Clase 1: 74%

Análisis: El modelo tiene un rendimiento balanceado entre precisión y recall, con un desempeño consistente en ambas clases.

4.2 K-Nearest Neighbors (KNN)

- **Descripción:** Clasifica las muestras basándose en la mayoría de los vecinos más cercanos.
- **Métricas de Evaluación:**
 - **Accuracy:** 68.8%
 - **Precision:** Clase 0: 68%, Clase 1: 69%
 - **Recall:** Clase 0: 62%, Clase 1: 74%
 - **F1-Score:** Clase 0: 65%, Clase 1: 72%

Análisis: El modelo tiene un mejor recall en la clase 1 (buena calidad), pero un rendimiento más bajo para la clase 0. La accuracy es inferior a la de Logistic Regression.

4.3 Random Forest

- **Descripción:** Modelo de ensamblado basado en múltiples árboles de decisión.
- **Hiperparámetros óptimos:** {'max_depth': None, 'min_samples_leaf': 2, 'min_samples_split': 5, 'n_estimators': 100}
- **Métricas de Evaluación:**
 - **Accuracy:** 76.5%
 - **Precision:** Clase 0: 75%, Clase 1: 78%
 - **Recall:** Clase 0: 76%, Clase 1: 77%
 - **F1-Score:** Clase 0: 75%, Clase 1: 78%

Análisis: El modelo **Random Forest** tuvo el mejor desempeño general en todas las métricas, con un AUC de **0.84**.

5. Evaluación de los Modelos

Modelo	Accuracy
Logistic Regression	73.5%
K-Nearest Neighbors	68.8%
Random Forest	76.5%

Curva ROC - Random Forest

La **curva ROC** para el modelo Random Forest muestra un **AUC de 0.84**, lo que indica una excelente capacidad predictiva.

6. Visualizaciones Clave

1. **Matriz de Confusión - Random Forest:**

- Buena precisión para ambas clases.
- La mayoría de las predicciones son correctas, aunque existen falsos negativos.

2. **Curva ROC - Random Forest:**

- La curva muestra un área bajo la curva (AUC) de **0.84**, lo que representa un excelente rendimiento.

3. **Comparación de Accuracy entre Modelos:**

- Random Forest tuvo la mayor accuracy, seguido de Logistic Regression y KNN.
-

7. Conclusiones

1. **Random Forest** fue el modelo con mejor rendimiento, mostrando mayor precisión, recall y F1-Score en comparación con Logistic Regression y KNN.
2. **Logistic Regression** ofreció un rendimiento sólido y balanceado, con un buen desempeño general.
3. **KNN** tuvo el rendimiento más bajo, especialmente en la capacidad de identificar la clase 0 (mala calidad).

Recomendación: Se recomienda utilizar **Random Forest** como el modelo final debido a su excelente precisión y robustez en la clasificación de la calidad del vino.